5.26总结:数据清洗、csv导入MySQL数据库

数据清洗

数据清洗即是将爬下来未处理的数据文件(txt、json等格式),转化为csv文件,一般需要通过 sed把里面不必要的字符删除,再以通过awk以一定规律分割,最后将脚本的处理结果重定向到 csv文件中。

一般处理思路:

sed掐头-去尾-换行-置空值-删符号-删元素(列名)-awk分隔、添加列名 > 重定向到csv

操作类型	sed/awk 实现方案	示例
去除结构标记	删除JSON头尾	sed 's/^{"data":\[//; s/\]}\$//'
字段分隔	替换分隔符为换行符	sed 's/},{/\n/g'
特殊字符处理	移除转义字符	sed 's/\\//g'
空值标准化	统一空值表示	sed 's/""/null/g'
引号处理	删除所有引号	tr -d '"'
字段提取	按位置重组字段	awk '{print \$2,\$1,\$3}'

导出的csv文件用excel打开可能中文显示会乱码(wps不会),需正常显示可如下操作:

右键csv文件以txt方式打开-另存为-设置编码为ANSI-确定保存 此后用excel打开此文件即可正常显示中文

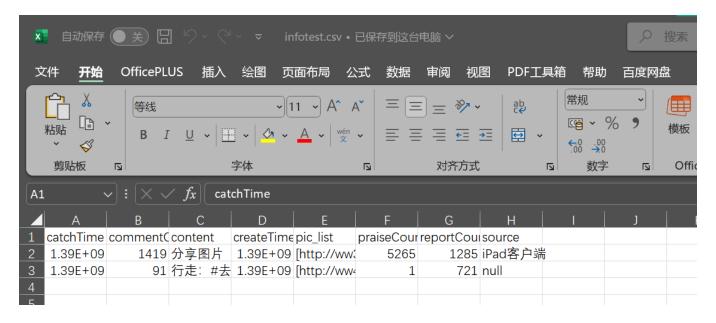
通过mysql对数据库服务器操作

mysql -h127.0.0.1 -P3306 -uroot -proot123456 test -e "select * from student"

- -h: MySQL服务器的ip地址或主机名;
- -u:连接MySQL服务器的用户名;
- -e: 执行mysql内部命令;
- -p:连接MySQL服务器的密码。
- -P: 连接MySQL服务器的端口

作业练习

```
#上机练习15
#1.清洗数据《infotest.txt》保存成《infotest.csv》
sed 's/\[{//g' /root/sh/infotest.txt # # 指头
sed 's/}\]//q' | #去尾
sed 's/""/null/g' #置空值
sed 's/"//q' | #删引号
#删除元素说明
sed 's/catchTime://g' |
sed 's/commentCount://g'
sed 's/content://g'
sed 's/createTime://g' |
sed 's/pic_list://g'
sed 's/praiseCount://g'
sed 's/reportCount://g'
sed 's/source://g'
#以逗号分割,添加列名,保存到csv
awk -v FS="," -v OFS="," 'BEGIN{print
"catchTime,commentCount,content,createTime,pic_list,praiseCount,reportCount,so
urce"}{print $1,$2,$3,$4,$5,$6,$7,$8}' \
> /root/sh/infotest.csv
```



```
#2.清洗数据《douban.txt》保存成《douban.csv》

sed 's/{"subjects":\[{//g' /root/sh/douban.txt | #掐头

sed 's/}\]}//g' | #去尾

sed 's/},{/\n/g' | #换行

sed 's/\\//g' | #删\号

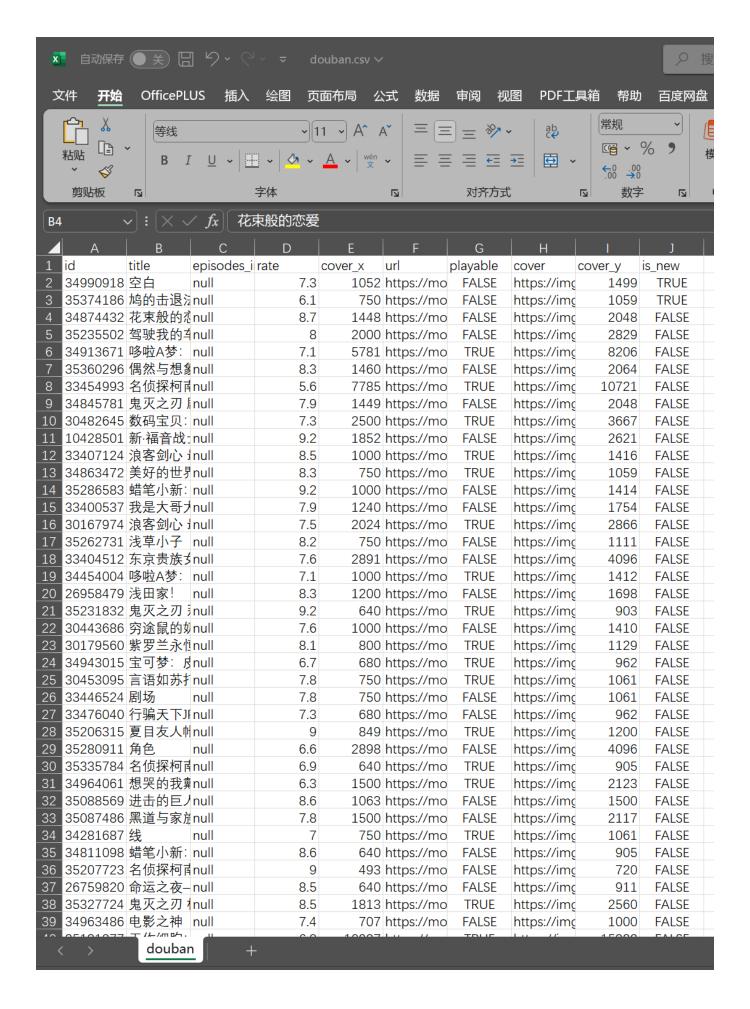
sed 's/""/null/g' | #置空值

sed 's/"//g' | #删引号

#删除元素说明

sed 's/id://g' |
```

```
sed 's/episodes_info://g' |
sed 's/rate://g' |
sed 's/cover_x://g' |
sed 's/url://g' |
sed 's/playable://g' |
sed 's/cover://g' |
sed 's/cover://g' |
sed 's/cover://g' |
sed 's/sover_y://g' |
sed 's/sis_new://g' |
#以逗号分割,添加列名,保存到csv
awk -v FS="," -v OFS="," 'BEGIN{print
"id,title,episodes_info,rate,cover_x,url,playable,cover,cover_y,is_new"}{print
$8,$4,$1,$2,$3,$5,$6,$7,$9,$10}' \
>/root/sh/douban.csv
```



```
#上机练习16
#编写shell脚本/root/shell/mysqlcsv.sh 实现:
#1. 如果douban表存在则删除
#2. 如果douban表不存在则新建
#3.导入douban.csv数据到douban表中,建表过程为根据导入的csv文件自动创建表
#4. 查询douban表验证结果
#设置mysql连接参数
dbhost="127.0.0.1" #主机名
dbprot=3306 #端口
dbuser="root" #用户名
dbpass="root123456" #密码
db="test" #表空间
#如果douban表存在则删除
sql1="drop table if exists douban"
mysql -h$dbhost -P$dbprot -u$dbuser -p$dbpass $db -e "$sql1"
#获取第一行(列名)
names=`head -n +1 /root/sh/douban.csv | sed 's/,/ /g'`
#找出最后一个列名
lastname='echo "$names" | awk '{print $NF}''
#如果douban表不存在则新建
sql2="create table if not exists douban("
for i in $names
   do
       if [ $i == "$lastname" ]
       then
           sql2="$sql2$i varchar(200))"
       else
           sql2="$sql2$i varchar(200),"
       fi
   done
mysql -h$dbhost -P$dbprot -u$dbuser -p$dbpass $db -e "$sql2"
#导入数据
sql3="LOAD DATA INFILE '/usr/local/mysql/data/douban.csv' INTO TABLE douban
CHARACTER SET utf8
FIELDS TERMINATED BY ','
LINES TERMINATED BY '\n'
IGNORE 1 LINES"
mysql -h$dbhost -P$dbprot -u$dbuser -p$dbpass $db -e "$sql3"
#查看表和数据
```

```
sql4="select * from douban"
mysql -h$dbhost -P$dbprot -u$dbuser -p$dbpass $db -e "$sql4"
```

